

Reliable and Trustworthy AI — Assignment #3

1. Problem 1: Marabou Resources 디렉터리 탐색

Marabou GitHub 저장소의 resources 디렉터리에는 신경망 검증을 위한 예제 모델, property 파일, 실행 보조 스크립트가 포함되어 있다. 디렉터리 README에 따르면 이 폴더는 Marabou tool paper의 실험 결과를 재현하기 위한 자료들로 구성된다. 조사 결과 가장 두드러진 모델 형식은 .nnet 과 .onnx이며, property는 별도의 .txt 또는 .vnnlib 파일로 분리되어 모델과 함께 입력된다.

1.1 주요 디렉터리 구조

경로	역할
resources/nnet	.nnet 형식 benchmark (ACAS XU, MNIST, CollisionAvoidance, TwinStreams)
resources/onnx	ONNX 모델, layer-zoo operator 테스트, CIFAR-10, traffic sign, TinyTaxiNet 등
resources/properties	ACAS XU property, builtin_property.txt, MNIST targeted robustness property
resources/onnx/vnnlib	VNNLIB 형식 property와 작은 ONNX 테스트 모델
resources/keras, mps, target	Keras .h5 모델, LP 예제(.mps), 어려운 query 모음(.ipq)

1.2 모델·데이터셋·property 형식 관찰

- 모델 형식은 .nnet 파일이 약 634 개로 가장 많고 .onnx 가 약 119 개이다. README 는 ONNX 를 main network format 으로 명시한다.
- 데이터셋은 학습용 raw data 보다 검증용 입력 명세 형태로 제공된다. 예: MNIST property 파일은 image*_target*_epsilon*.txt 명명 규칙으로 픽셀별 perturbation bound 와 target class 비교 조건을 담는다. 검증 query 는 모델 + property 조합으로 실행된다.
- 복잡한 ONNX 연산이 포함된 모델은 onnx-simplifier 로 단순화한 simp 버전이 별도 제공되며, Marabou 가 처리 가능한 연산 범위에 제한이 있음을 보여준다.

이 탐색의 시사점은, Problem 2의 외부 모델은 (a) resources에 이미 포함된 ACAS XU·MNIST·CIFAR-10 등과 겹치지 않고, (b) Gemm·ReLU 중심의 작은 fully connected 구조로 두며, (c) ONNX 형식으로 export하여 maraboupy로 직접 다루는 것이 가장 안전한 선택이라는 점이다.

2. Problem 2: 외부 모델·데이터셋으로 Marabou 실행

2.1 모델과 데이터셋

데이터셋은 sklearn.datasets.load_wine()의 Wine dataset을 선택했다. 178개 sample, 13개 numeric feature, 3개 wine cultivar class로 구성된 작은 tabular classification 문제다. Iris보다 feature 수가 많아 검증 과제로 의미가 있고, MNIST/CIFAR-10보다 입력 차원이 훨씬 작아 SMT 기반 검증의 timeout 위험이 낮다.

모델은 13 -> 16 -> ReLU -> 8 -> ReLU -> 3 구조의 작은 MLP로 직접 학습했다. 마지막 layer는 logits를 그대로 출력하여 Marabou에서 두 class 출력값을 직접 선형 비교 constraint로 비교할 수 있게 했다. Wine dataset에 대한 기존 공개 모델 대부분이 tree 기반이거나 Marabou 호환에 부적합한 구조였기 때문에, 모델 구조·activation·전처리·ONNX export 방식을 통제할 수 있는 직접 학습 방식을 택했다.

2.2 학습과 ONNX Export

PyTorch에서 stratified train/test split (test 25%, seed 7)와 StandardScaler로 정규화한 입력을 사용했다. Adam optimizer, learning rate 0.01, CrossEntropyLoss, 800 epoch로 학습 후 ONNX opset 18로 export했고, ONNX Runtime 출력과 PyTorch 출력의 최대 절대 오차로 변환의 수치적 일관성을 검증했다.

항목	값
Train accuracy	1.0000
Test accuracy	0.9778
ONNX/PyTorch max abs diff	9.5e-7
ONNX opset	18

2.3 검증 property 및 sample 선택

test set에서 정답으로 분류된 sample 중 top-1과 top-2 logit 차이(margin)가 가장 작은 3개를 검증 대상으로 골랐다. 모델이 맞추긴 했지만 거의 틀릴 뻔한 샘플들에서 robustness 경계가 빠르게 드러나기 때문이다. logit margin이 매우 큰 샘플로만 검증하면 모든 query가 UNSAT으로 평탄해져 도구의 동작을 보여주지 어렵다는 사전 실험 관찰을 반영한 결정이다.

각 normalized feature x_i 에 대해 $x_i - \varepsilon \leq x'_i \leq x_i + \varepsilon$ 의 ℓ_∞ 입력 box를 부여하고, 원래 class c에 대해 다른 target class j마다 반례 조건 $y_j \geq y_c$ (Marabou 입력으로는 $y_c - y_j \leq 0$)를 검사한다. $\varepsilon \in \{0.01, 0.05, 0.1, 0.3, 0.5, 1.0\}$ 을 sweep했다.

2.4 실행 결과

세 sample은 각각 다른 robustness 양상을 보였다 (실행: WSL2 Ubuntu 24.04, Python 3.11 micromamba, maraboupy 2.0.0).

Sample	margin	logits (c0 / c1 / c2)	true / pred	최대 robust ϵ	첫 non-robust ϵ
low_margin_1	0.002	-5.15 / 2.98 / 2.97	1 / 1	—	0.01
low_margin_2	0.293	0.76 / 0.47 / -1.85	0 / 0	—	0.01
low_margin_3	4.313	-4.14 / 4.27 / -0.04	1 / 1	0.10	0.30

low_margin_1 (margin $\approx$ 0)은 class_1과 class_2 logit이 사실상 동률(2.976 vs 2.973)이다. $\epsilon=0.01$ 에서 즉시 class_2 방향 SAT이 발견되었고, Marabou가 반환한 반례의 logit은 [-5.18, 2.991, 2.991]로 정확히 결정 경계 위에 있다. 반례를 inverse-transform한 원본 측정값은 alcohol 12.64→12.63, proline 450→446.8 수준의 노이즈에 가까운 변화로, SMT 기반 검증이 통계적 평가가 놓치는 예측의 불안정성을 형식적으로 잡아 낸다는 점을 보여준다.

low_margin_2 (margin = 0.293)는 비대칭 robustness 사례다. class_2(logit -1.85)는 멀리 떨어져 있어 $\epsilon=0.05$ 까지 UNSAT으로 유지되지만, class_1 방향(logit 0.47)은 $\epsilon=0.01$ 에서부터 SAT이 발생한다.

low_margin_3 (margin = 4.313)은 robustness 경계가 가장 깔끔하게 드러난 사례다. $\epsilon \leq 0.1$ 까지 양쪽 target에 대해 UNSAT으로 형식적 robustness가 성립하고, $\epsilon=0.3$ 에서 class_2 방향이 먼저 깨진 뒤 $\epsilon=0.5$ 에서 class_0 방향까지 SAT으로 전환된다. 즉 normalized feature space 기준 robust radius가 (0.1, 0.3] 구간에 존재한다.

ϵ	target=class_0	target=class_2	robust
0.01	UNSAT	UNSAT	✓
0.05	UNSAT	UNSAT	✓
0.10	UNSAT	UNSAT	✓
0.30	UNSAT	SAT	×
0.50	SAT	SAT	×
1.00	SAT	SAT	×

3. Marabou의 강점과 한계 (사용 경험 기반)

3.1 강점

- 정확한 형식 증명: SMT 기반이므로 UNSAT은 입력 box 내 모든 점에 대한 보장을 제공한다. 통계적 robust accuracy와는 본질이 다른 결론을 준다.
- 유의미한 반례와 방향별 분석: SAT 시 반환되는 반례를 inverse-transform 하면 원본 feature 단위에서 결정을 뒤집는 구체적 변화를 시각화할 수 있고(low_margin_1: $\epsilon=0.01$ 반례가 wine 측정값에 거의 노이즈 수준 변화만 가했음에도 class를 뒤집음), target class 별로 query를 분리하면 단일 robust 판정을 넘어 비대칭 안전 마진을 잡아낼 수 있다(low_margin_2 사례).
- ONNX 친화성과 작은 모델에서의 우수한 속도: 13×16×8×3 규모에서 단일 query가 SAT 탐색 포함 1~3 ms에 종료되어 ϵ sweep을 가벼운 비용으로 수행할 수 있었다.

3.2 한계

- 지원 연산의 제한: layer-zoo와 cifar10 simp 모델의 존재가 보여주듯 복잡한 ONNX 연산은 단순화가 필요할 수 있다. 본 과제에서 sigmoid/softmax를 의도적으로 제거하고 logits를 출력한 것도 같은 이유다.
- 환경-API 제약: maraboupy는 Python 3.8~3.11만 지원하므로 Ubuntu 24.04 기본 Python 3.12에서는 별도 가상환경(예: micromamba)이 필요했고, Windows native build가 권장되지 않아 WSL2 Ubuntu에서 작업했다. 또한 Marabou 2.0의 Python API에서는 Equation을 MarabouUtils에서 import해야 하고 solve의 반환은 (exit_code, values, stats) 형태이며 SAT 판정은 exit_code 문자열로 처리해야 했다. 설치 확인은 maraboupy에서 ONNX 모델을 로드하고 test.py의 verification query가 정상 실행되는 것으로 확인했다.
- scalability: 13 차원 입력 MLP는 의도적으로 보수적인 설정이었다. CNN 또는 입력 차원 수백 이상 모델로 확장 시 SMT search space가 커져 timeout 위험이 높다.
- 통계 정확도 $\neq$ robustness: test accuracy 97.78%인 모델에서도 logit margin이 0.002 수준인 정답 샘플이 존재하며, $\epsilon=0.01$ 의 미세한 perturbation으로 결정이 뒤집힐 수 있음을 Marabou가 정량화해 드러냈다.

4. 결론

세 low-margin test sample에 대한 ϵ sweep 결과, (i) margin $\approx$ 0 sample은 $\epsilon=0.01$ 부터 즉시 깨지고, (ii) margin $\approx$ 0.3 sample은 target 방향별 비대칭 robustness를, (iii) margin $\approx$ 4.3 sample은 $\epsilon \in (0.1, 0.3]$ 구간의 명확한 robust radius를 가짐을 형식적으로 확인했다. Marabou는 작고 ReLU 중심의 모델에서 정확한 검증과 의미 있는 반례를 빠르게 제공하지만, 지원 연산·모델 규모·환경 구성에서의 사전 작업이 명확한 한계로 드러났다.